

# ADAR2 NES SD40 Linker 设计中期结果全量整理

基于 11–20 Å 多距离设计、三模型结构预测、RMSD/Vina 门控与 SD40 几何评分

数据范围：匿名化全量结果档案 | 整理日期：2026-09-30

## 执行摘要

本次整理覆盖匿名提交包中的 13,011 条来源记录及匿名归档根目录结果文件。在线 MMseqs2 批次共获得 292 条去重 ProteinMPNN 设计序列，完成 588 个 Boltz-2 模型预测。采用 Linker C $\alpha$  RMSD 严格小于 2.0 Å、至少 2/3 模型通过，以及 Vina 最佳分数不高于 -6.0 kcal/mol、至少 2/3 模型通过的门控。

共有 22 个正式候选的最终分严格高于 GGGGSGGGGS 基线 24.1035。当前最高候选为 LRELLERLLT (15 Å)，最终分 60.5687，高于基线 36.4652。

这些结果支持候选优先级排序，但仍属于计算筛选证据。Vina 分数不等价于实验结合自由能，Ranker 是基于设定权重的几何复合指标，最终入选仍需表达、结合、编辑活性、定位与细胞毒性实验验证。

## 研究设计与结果组织

结果按文献常见的证据链组织：先说明研究设计和数据完整性，再展示跨候选标准化比较、三模型重复稳健性、结构与对接解释，最后给出综合候选分层、限制和验证路线。三篇参考文献仅用于结果呈现逻辑，不作为本项目数值来源。

图 7 当前证据层级与下一步验证

计算筛选支持候选优先级，但不能替代生化与细胞实验



图 7 当前证据层级与下一步验证

## 数据完整性与分析范围

匿名包的 VALIDATION\_REPORT 状态为 PASS；在线批次 11–20 Å 均包含 RFdiffusion、ProteinMPNN、序列 QC、Boltz-2、Linker RMSD、Vina 和 Ranker 阶段。根目录两份 XLSX 与包内副本哈希一致。全部大体积结构、MSA 和日志文件未复制到派生目录，而是通过相对路径、大小、SHA256、阶段和用途写入全量来源索引。

| 来源类别        | 文件数  | 总大小 GiB |
|-------------|------|---------|
| Boltz-2/MSA | 7035 | 5.23    |
| ProteinMPNN | 300  | 0.01    |
| RFdiffusion | 84   | 0.01    |
| RMSD 门控     | 217  | 0.00    |
| SD40 Ranker | 406  | 0.10    |
| Vina 对接     | 2323 | 0.14    |
| 其他原始产物      | 1459 | 4.78    |
| 完整性与复现      | 5    | 0.00    |

| 来源类别  | 文件数  | 总大小 GiB |
|-------|------|---------|
| 序列 QC | 77   | 0.00    |
| 汇总结果  | 97   | 0.02    |
| 运行日志  | 1008 | 0.01    |

## 筛选漏斗

**图 1 各目标距离的筛选漏斗**  
RFdiffusion → ProteinMPNN → 序列QC → Boltz-2 → RMSD → Vina → Ranker




图 1 11-20 Å 在线批次的候选筛选漏斗

| 距离 Å | RF 骨架 | MPNN 去重 | QC 通过 | Boltz 候选 | RMSD 通过 | Vina 通过 | Ranker 模型 |
|------|-------|---------|-------|----------|---------|---------|-----------|
| 11   | 3     | 29      | 28    | 29       | 1       | 1       | 6         |
| 12   | 3     | 29      | 27    | 28       | 12      | 12      | 39        |
| 13   | 3     | 30      | 26    | 27       | 10      | 10      | 33        |
| 14   | 3     | 29      | 9     | 10       | 8       | 8       | 27        |
| 15   | 3     | 29      | 11    | 12       | 11      | 11      | 36        |
| 16   | 3     | 28      | 19    | 20       | 18      | 16      | 51        |
| 17   | 3     | 30      | 22    | 23       | 18      | 18      | 57        |

| 距离 Å | RF 骨架 | MPNN 去重 | QC 通过 | Boltz 候选 | RMSD 通过 | Vina 通过 | Ranker 模型 |
|------|-------|---------|-------|----------|---------|---------|-----------|
| 18   | 3     | 29      | 18    | 19       | 15      | 14      | 45        |
| 19   | 3     | 29      | 14    | 15       | 13      | 13      | 42        |
| 20   | 3     | 30      | 12    | 13       | 11      | 11      | 36        |

## 候选分数与基线比较




图 2 正式评分候选与 GGGGSGGGGS 基线比较

图 3 优于基线的头部候选  
最终分为三个 Boltz-2 模型 Ranker 总分的中位数




图 3 优于基线的头部候选

| 距离 Å | Linker      | 最终分     | 较基线      | Linker RMSD Å | Vina  | SD40 RMSD Å |
|------|-------------|---------|----------|---------------|-------|-------------|
| 15   | LRELLERLLT  | 60.5687 | +36.4652 | 0.484         | -6.30 | 4.306       |
| 20   | LEELLEKLKP  | 59.7116 | +35.6081 | 0.706         | -6.30 | 4.025       |
| 20   | EEKAEEESK   | 59.4952 | +35.3917 | 0.402         | -6.60 | 4.291       |
| 20   | EEELEKALSE  | 57.4788 | +33.3753 | 0.465         | -6.90 | 4.141       |
| 20   | LEEILRKLRE  | 55.5929 | +31.4894 | 0.450         | -6.00 | 4.335       |
| 20   | LEELLKKLSE  | 54.7321 | +30.6286 | 0.516         | -6.20 | 3.980       |
| 15   | DELRREKEEK  | 50.9843 | +26.8808 | 0.772         | -6.10 | 4.401       |
| 20   | EEKRREEEKE  | 48.9506 | +24.8471 | 0.457         | -7.10 | 4.406       |
| 19   | EEPLRKLLEQ  | 33.3418 | +9.2383  | 0.385         | -7.80 | 4.640       |
| 16   | EELLEEELEKE | 29.6744 | +5.5709  | 0.944         | -7.20 | 3.136       |
| 18   | EELLKKLLDE  | 28.5511 | +4.4476  | 0.342         | -7.30 | 4.413       |
| 12   | EEVTELGETT  | 28.5037 | +4.4002  | 1.904         | -7.50 | 3.020       |

### 三模型稳健性与门控





图 4 Linker RMSD 与 Vina 候选通过率

RMSD 采用每个候选的三个 Boltz-2 模型分别判定，单模型 Linker C $\alpha$  RMSD 必须严格小于 2.0 Å；候选至少 2/3 模型通过。Vina 同样按模型判定，在线批次阈值为不高于 -6.0 kcal/mol，候选至少 2/3 模型通过。最终分取三个 Ranker 模型总分的中位数，以降低单个结构预测的偶然性。

# 序列组成与质量控制

**图 5 Linker 序列组成与 QC**  
各距离的候选均值；净电荷显示为中位数



**图 5 Linker 序列组成与 QC 概览**

序列 QC 表保留了 K/R 比例、疏水比例、净电荷和失败原因，可用于识别过强正电、过度疏水或其他不利组成。图中展示各距离的整体分布，不应以单一组成指标替代结构和功能证据。

# 16 Å 批次敏感性

**图 6 两个 16 Å 批次的敏感性比较**  
MSA方式和Vina阈值不同，因此仅用于批次敏感性分析

| 指标     | 早期单序列MSA | 后期在线MMseqs2 |
|--------|----------|-------------|
| Vina阈值 | ≤ -7.0   | ≤ -6.0      |
| MPNN去重 | 28       | 28          |
| QC通过   | 19       | 19          |
| RMSD通过 | 18       | 18          |
| Vina通过 | 2        | 16          |
| 基线分    | 17.0274  | 24.1035     |
| 最高候选分  | 16.0305  | 29.6744     |

注意：批次之间同时改变了MSA来源和Vina阈值，不能把差异解释为16 Å本身造成。

**图 6 早期单序列 MSA 与后期在线 MMseqs2 的 16 Å 批次比较**

早期 16 Å 批次使用本地单序列 A3M，Vina 阈值为不高于 -7.0 kcal/mol，基线分 17.0274；后期 16 Å 重跑使用在线 MMseqs2 MSA，Vina 阈值为不高于 -6.0 kcal/mol，基线分 24.1035。由于 MSA 来源和筛选阈值同时变化，两个批次只能用于流程敏感性分析，不能解释为距离效应。跨距离主比较统一采用后期在线批次。

# 综合候选分层

建议把候选分为三级。一级候选同时满足：最终分高于基线、RMSD 与 Vina 均至少 2/3 通过、三模型分数离散较小、序列 QC 通过；二级候选满足硬门控但存在某一项边缘指标；三级候选保留为机制或序列多样性备选。派生工作簿保留所有候选和逐模型字段，便于按不同实验优先级重新筛选。

| 优先级 | 距离 Å | Linker      | 最终分     | RMSD 通过 | Vina 通过 | QC |
|-----|------|-------------|---------|---------|---------|----|
| 1   | 15   | LRELLERLLT  | 60.5687 | 3/3     | 2/3     | 通过 |
| 2   | 20   | LEELLEKLKP  | 59.7116 | 3/3     | 2/3     | 通过 |
| 3   | 20   | EEEKAEEESK  | 59.4952 | 2/3     | 3/3     | 通过 |
| 4   | 20   | EEELEKALSE  | 57.4788 | 3/3     | 3/3     | 通过 |
| 5   | 20   | LEEILRKLRE  | 55.5929 | 3/3     | 2/3     | 通过 |
| 6   | 20   | LEELLKKLSE  | 54.7321 | 3/3     | 3/3     | 通过 |
| 7   | 15   | DELRRKEEEK  | 50.9843 | 3/3     | 3/3     | 通过 |
| 8   | 20   | EEKRREEEKE  | 48.9506 | 3/3     | 3/3     | 通过 |
| 9   | 19   | EEPLRKLEEQ  | 33.3418 | 3/3     | 3/3     | 通过 |
| 10  | 16   | EELLEEELEKE | 29.6744 | 3/3     | 3/3     | 通过 |

# 方法与参数

| 项目         | 设置                                                                              |
|------------|---------------------------------------------------------------------------------|
| 结构骨架       | RFdiffusion，每个目标距离 3 个 backbone                                                 |
| 序列设计       | ProteinMPNN，每个距离请求 30 条，结果按唯一序列统计                                               |
| 结构预测       | Boltz-2，每候选 3 个模型；在线批次使用 MMseqs2 MSA                                            |
| RMSD 门控    | Linker Cα RMSD < 2.0 Å；至少 2/3 模型通过                                              |
| Vina 门控    | 在线批次最佳分数 ≤ -6.0 kcal/mol；至少 2/3 模型通过                                            |
| Ranker 模型分 | $100 \times (0.3 \times S\_RMSD + 0.3 \times S\_contact + 0.4 \times S\_clash)$ |
| 候选最终分      | 三个 Boltz-2 模型 Ranker 总分的中位数                                                     |
| 对照         | GGGGSGGGGS；在线批次基线 24.1035                                                       |

## 限制与下一步

- Boltz-2 单序列或 MSA 质量会影响结构置信度；模型间一致性可降低但不能消除该不确定性。
- Linker RMSD 衡量与 RFdiffusion 骨架的一致性，不直接等价于功能保持或真实构象分布。
- Vina 是近似打分；当前阈值是流程门控，不应解释为实验结合常数。
- Ranker 权重属于预设决策函数，候选排序需通过权重敏感性和实验数据校准。
- 下一步应优先验证一级候选，并保留基线、空白连接和代表性失败候选作为对照。

## 数据可用性与复现

本报告的主表和图均由匿名化全量结果档案重建。完整相对路径和 SHA256 位于 06\_全量来源索引；解析后的候选级与模型级数据位于 02\_核心数据表和 04\_补充表与补充图。轻量展示目录只包含派生表、图和方法说明，不包含大型 A3M、NPZ、压缩包或模型缓存。

## 参考文献

1. AI-redesigned starting points and outcomes enhance protein evolution
2. Design, construction and characterization of a set
3. PottsMPNN